Tài liệu hướng dẫn

Gán nhãn dữ liệu cho văn bia chữ Nôm

Mục lục

1 Giới thiệu **1**

2 Hướng dẫn **2**

2.1 Tài nguyên . . . 2

2.2 Môi trường . . . 3

2.3 Chuẩn bị Input . . . 4

2.3.1 Model . . . 4

2.3.2 Dataset . . . 4

2.4 Hướng dẫn sử dụng . . . 5

2.4.1 Chọn ảnh văn bia . . . 5

2.4.2 Kiểm tra nội dung . . . 6

2.4.3 Kiểm tra, điều chỉnh Bounding Box và sắp xếp thứ tự . . . 8

2.4.4 Thực hiện gắn trạng thái bounding box và sắp xếp . . . 9

2.4.5 Cắt vùng ảnh không chứa thông tin (Crop) . . . 12

2.4.6 Xác minh lại thông tin . . . 13

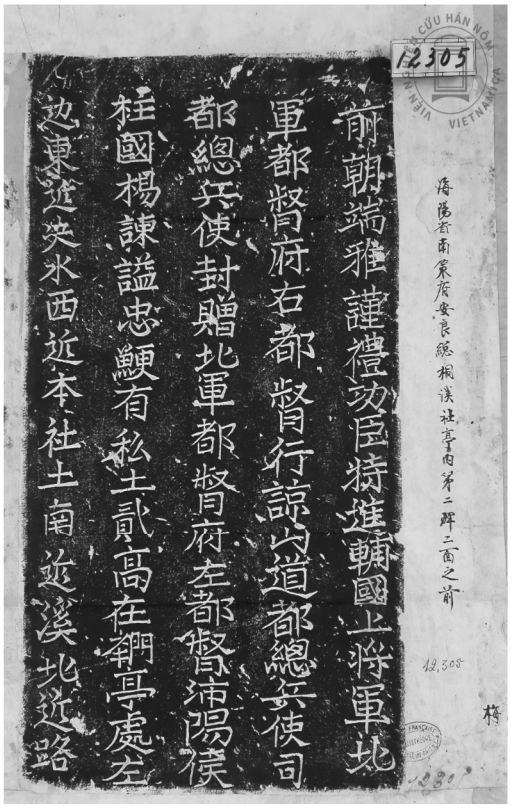
2.5 Yêu cầu nộp bài . . . 14

1 Giới thiệu

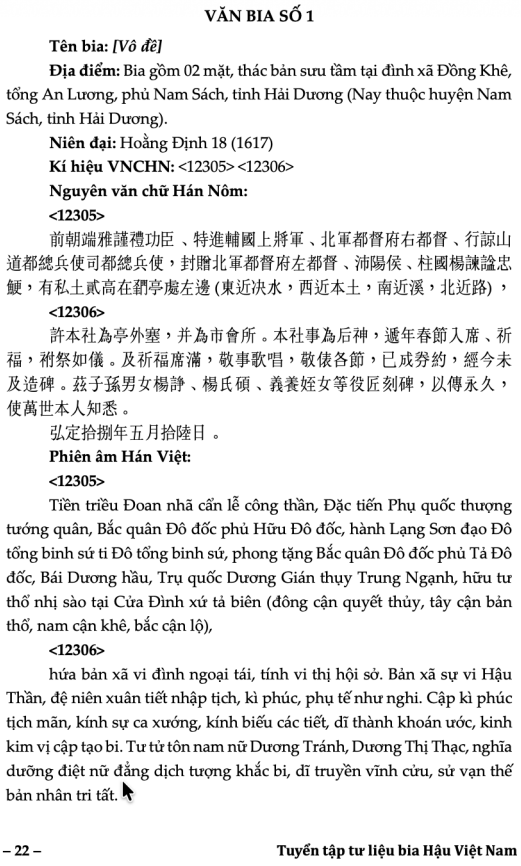
Các tài liệu lịch sử về văn bia chữ Nôm thường được lưu trữ dưới dạng sách hoặc bản scan PDF, trong đó có hình ảnh văn bia kèm theo phần trích dẫn và giải thích nội dung. Tuy nhiên, các dữ liệu này chưa được tổ chức dưới dạng mà máy tính có thể trực tiếp khai thác, đặc biệt là hình ảnh và nội dung chữ Nôm tương ứng chưa được liên kết và gán nhãn.

Vì vậy, bài tập tập trung vào việc tiền xử lý và gán nhãn dữ liệu, chuyển các tư liệu trên thành tập dữ liệu có cấu trúc, phục vụ cho việc huấn luyện các mô hình xử lý văn bản Hán Nôm.

Trong các tài liệu, thông thường nội dung văn bia cổ sẽ bao gồm hai dạng: ảnh và phần chữ Nôm trong ảnh (ảnh minh họa).



Hình 1: Mẫu văn bia chữ Nôm thế kỉ XVII



VĂN BIA SỐ 1

Tên bia: *[Vô đề]*

Địa điểm: Bia gồm 02 mặt, thác bản sưu tầm tại đình xã Đồng Khê, tổng An Lương, phủ Nam Sách, tỉnh Hải Dương (Nay thuộc huyện Nam Sách, tỉnh Hải Dương).

Niên đại: Hoằng Định 18 (1617)

Kí hiệu VNCHN: <12305> <12306>

Nguyên văn chữ Hán Nôm:

<12305>

前朝端雅謹禮功臣 、特進輔國上將軍 、北軍都督府右都督 、行諒山道都總兵使司都總兵使，封贈北軍都督府左都督 、沛陽侯 、柱國楊諫諡忠鯁，有私土貳高在碧亭處左邊 (東近泱水，西近本土，南近溪，北近路)，

<12306>

許本社為亭外塞，并為市會所 。本社事為后神，遞年春節入席 、祈福，祫祭如儀 。及祈福席潘，敬事歌唱，敬俵各節，已成券約，經今未及造碑 。茲子孫男女楊諍 、楊氏碩 、義養姪女等役匠刻碑，以傳永久，使萬世本人知悉 。

弘定拾捌年五月拾陸日 。

Phiên âm Hán Việt:

<12305>

Tiền triều Đoan nhã cần lễ công thần, Đặc tiến Phụ quốc thượng tướng quân, Bắc quân Đô đốc phủ Hữu Đô đốc, hành Lạng Sơn đạo Đô tổng binh sứ ti Đô tổng binh sứ, phong tặng Bắc quân Đô đốc phủ Tả Đô đốc, Bái Dương hầu, Trụ quốc Dương Gián thụy Trung Ngạnh, hữu tư thổ nhị sào tại Cửa Đình xứ tả biên (đông cận quyết thủy, tây cận bản thổ, nam cận khê, bắc cận lộ),

<12306>

hứa bản xã vi đình ngoại tái, tính vi thị hội sở. Bản xã sự vi Hậu Thần, đệ niên xuân tiết nhập tịch, kì phúc, phụ tế như nghi. Cập kì phúc tịch mãn, kính sự ca xướng, kính biếu các tiết, dĩ thành khoán ước, kinh kim vị cập tạo bi. Tư tử tôn nam nữ Dương Tránh, Dương Thị Thạc, nghĩa dưỡng điệt nữ đẳng dịch tượng khắc bi, dĩ truyền vĩnh cửu, sử vạn thế bản nhân tri tất.

Hình 2: Phần thông tin tương ứng với Hình 1

Nhiệm vụ của chúng ta là gán nhãn các vị trí tương ứng với từng chữ ở trong hình của văn bia. Về quy trình thực hiện, có thể chia thành các bước chính:

1. Thực hiện trích xuất phần nội dung văn bia
2. Thực hiện xác định bounding box cho từng chữ trên văn bia
3. Thực hiện gán nhãn chữ tương ứng với vị trí bounding box trên văn bia
4. Thực hiện crop phần dư thừa trong ảnh văn bia

2 Hướng dẫn

2.1 Tài nguyên

- **Kaggle Notebook:** https://www.kaggle.com/code/ynvnghi/annotation-sinonom/

  Nhấn `Copy & Edit` để mở được `Notebook`.

- **Video Demo:** https://youtu.be/Xz1oZ6dVW9Y

- **Data**: Phần này bao gồm hình ảnh văn bia, file `.json` chứa nội dung và thông tin các mặt bia và các file PDF gốc.

  Mỗi file PDF có thể có nhiều văn bia, một văn bia có thể có nhiều mặt bia, và mỗi mặt bia là một hình ảnh ta cần phải gán nhãn.

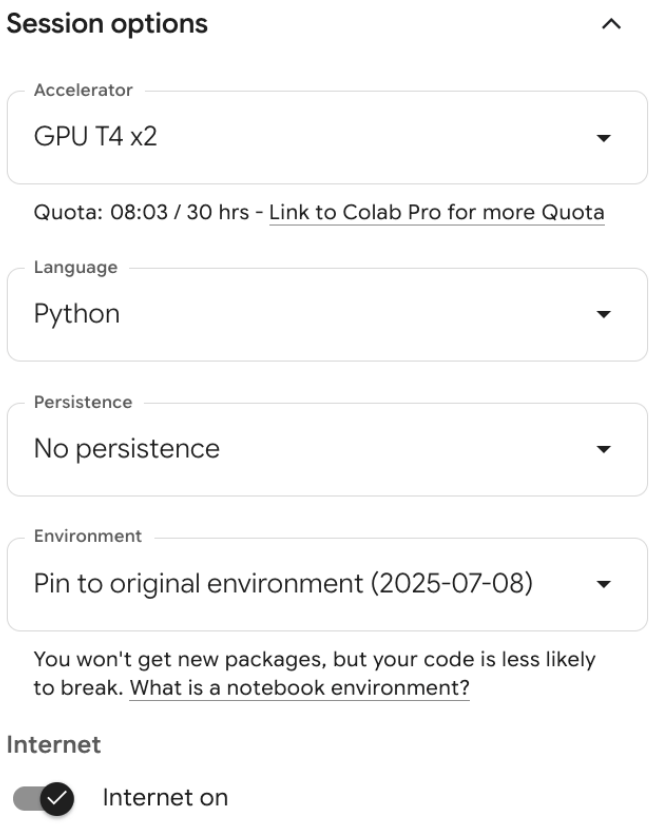
  Dựa vào trường `source_file` của mỗi văn bia để xác nhận nó thuộc PDF nào, phục vụ cho việc dò và kiểm tra dữ liệu ở các bước sau.

Lưu ý. Video demo ứng dụng chỉ thể hiện sơ lược cách sử dụng và giao diện, kích thước bouding box và thao tác trong video không phải là tiêu chuẩn tham khảo cho độ chính xác của việc gán nhãn.

2.2 Môi trường

Chương trình có thời gian thực thi tương đối dài và yêu cầu tài nguyên GPU để đảm bảo quá trình xử lý được thực hiện hiệu quả. Do đó, người thực hiện nên sử dụng các nền tảng điện toán trực tuyến có hỗ trợ GPU, chẳng hạn như Google Colab hoặc Kaggle, nhằm thuận tiện cho việc triển khai và chạy chương trình. Notebook được cung cấp được viết với môi trường Kaggle và mô hình detection cũng được lưu trên Kaggle, vì vậy khuyến khích dùng nền tảng Kaggle để thực hiện.

Lưu ý. Khi thực hiện Edit Notebook, cần phải kiểm tra phần **Session Options** có setup giống với Hình 3, để tương thích với các package Python được dùng trong code và Internet được bật để clone được Repo Github.

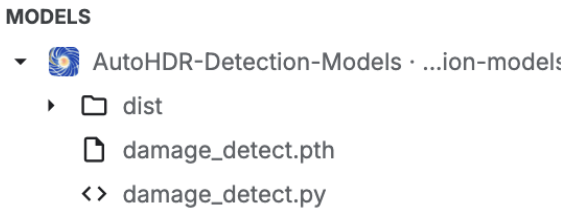


Hình 3: Session Options Settings

2.3 Chuẩn bị Input

2.3.1 Model

Kiểm tra xem liệu vị trí tương ứng với ảnh đã có model và bao gồm các tập tin cần thiết chưa, nếu như Hình 4 là thành công.

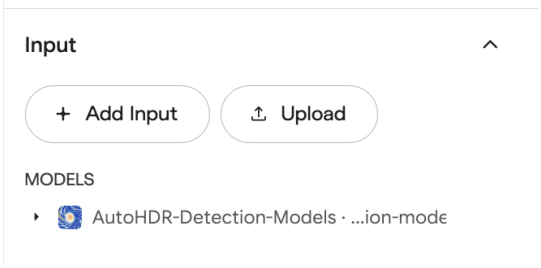


Hình 4: Model sẵn sàng sử dụng

2.3.2 Dataset

Người dùng được cung cấp các tệp tin bao gồm:

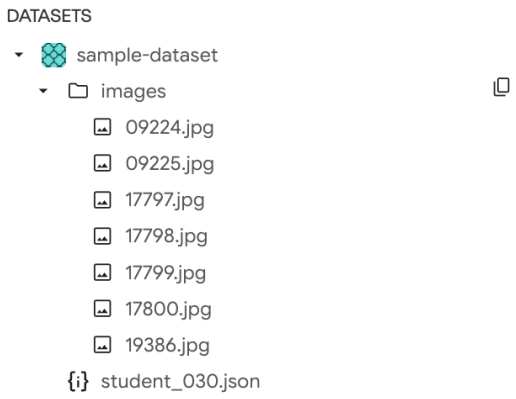
- Tệp tin JSON: Chứa phần nội dung và một số thông tin liên quan của các văn bia.
- Thư mục ảnh: Chứa các ảnh tương ứng với các mã văn bia có trong tệp tin JSON (người dùng tự gộp các ảnh được cung cấp thành folder).



Hình 5: Vị trí nút Upload

Người dùng nhấn Upload và chọn New Dataset để tải lên dữ liệu lên, cần đưa các ảnh được cung cấp vào 1 folder rồi hẵng up folder đó lên, như hình ví dụ ở Hình 6. Sau đó, thực hiện thay đổi các biến chứa đường dẫn tương ứng với project, bao gồm các biến trong Hình 7 bằng cách copy đường dẫn đến file của mình (hover lên file rồi nhấn ô vuông) rồi passte vào:

- `SOURCE_JSON`: Đường dẫn đến tệp tin JSON chứa nội dung PDF đã được cung cấp.
- `IMAGE_DIR`: Đường dẫn của thư mục chứa các ảnh của các văn bia tương ứng với nội dung của JSON.



Hình 6: Kết quả sau khi Upload thành công

```
IMAGE_DIR = Path('/kaggle/input/datasets/ynvnghi/sample-dataset/images')
SOURCE_JSON = Path('/kaggle/input/datasets/ynvnghi/sample-dataset/student_030.json')
```

Hình 7: Các biến cần thay đổi

2.4 Hướng dẫn sử dụng

Notebook được cung cấp với các cell đã được thiết lập và thực thi sẵn nhằm hỗ trợ quá trình trích xuất nội dung từ văn bia. Tuy nhiên, do đặc thù của dữ liệu hình ảnh và chất lượng văn bia, kết quả vẫn cần được kiểm tra, xác thực và hiệu chỉnh thủ công.

Sau khi thực hiện `Run all`, tại cell cuối cùng của notebook sẽ xuất hiện một URL dẫn đến giao diện web local được xây dựng bằng Gradio, thực hiện chọn **public URL**. Giao diện này được sử dụng để kiểm tra và điều chỉnh các kết quả chưa chính xác của model nhận diện và gán nhãn.

Ghi chú

Về thời gian chạy, có một số lưu ý về các tác vụ tốn nhiều thời gian xử lí như sau:

- Thời gian chạy Notebook đến khi có URL (không kể thời gian Download phần Model trong Dataset): Từ 10 đến hơn 20 phút (tùy thuộc vào tốc độ server).
- Thời gian Loading Fonts: Khoảng 5 - 10 phút.
- Thời gian chạy Detection: Tùy thuộc vào ảnh, có thể từ 30 giây đến vài phút.

2.4.1 Chọn ảnh văn bia

Bước 1: Chọn ảnh văn bia mình muốn gán nhãn.

Bước 2: Thực hiện chọn `Start Verfication` để bắt đầu quá trình gán nhãn cho văn bia đã chọn.

Ở phần này, có thể chọn `History` để kiểm tra xem mình đã thực hiện gán nhãn và chưa gán nhãn cho ảnh nào.

2.4.2 Kiểm tra nội dung

Mục đích. Đảm bảo phần nội dung được trích xuất giống với text tương ứng trong PDF. (không quan sát hình văn bia ở bước này).

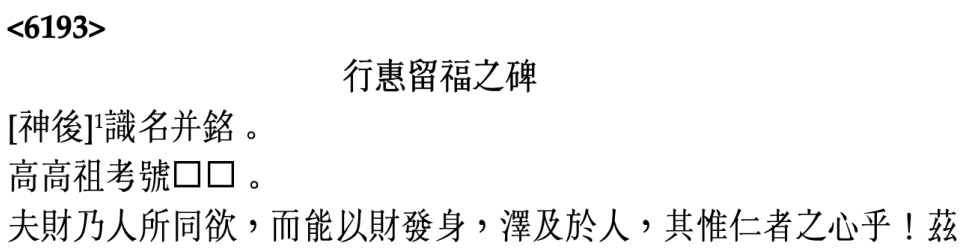
Nguyên nhân. Do bản thân các tệp tin PDF có thể gặp lỗi khi nhúng font, nên chương trình thực hiện so khớp từng hình vẽ kí tự (glyph) với bảng kí tự của font tương ứng để suy ra được Unicode. Vì vậy, không đảm bảo kết quả sinh ra sẽ giống với những gì có trong PDF. Vì vậy, bản thân người dùng phải tự xác minh lại các thông tin này.

Nội dung chữ trong PDF được đọc theo chiều đọc từ trên xuống dưới, **từ trái sang phải**.

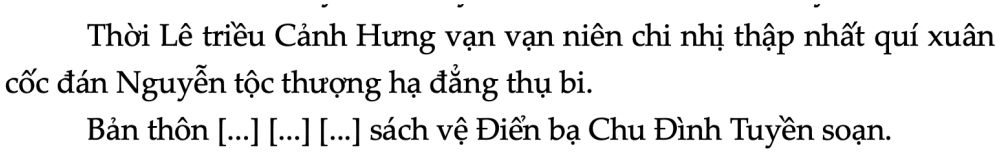
Hướng dẫn.

Bước 1: Thực hiện chuẩn hóa lại phần nội dung theo các quy tắc sau:

- **Đối với các chữ bị mất**: Biểu diễn bằng dấu □ **(Mã Unicode: U+25A1)** với mỗi chữ bị mất, bao gồm cả trường hợp chữ bị mất là chữ Quốc Ngữ và chữ Hán/ Nôm, xem Hình 8 và Hình 9.



Hình 8: Ví dụ chữ Nôm bị mất (2 kí tự □)

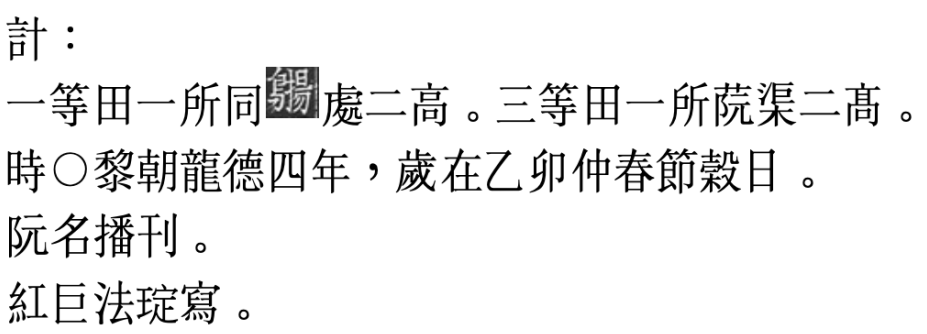


Hình 9: Ví dụ chữ Quốc ngữ bị mất (kí hiệu [...])

Ghi chú

Đôi khi kí hiệu [...] biểu diễn cho 5 chữ bị mất, đôi khi là 1 chữ bị mất, vì vậy cần đọc kĩ phần quy định đối với từng PDF, nằm ở phần Phàm Lệ ở đầu mỗi PDF ứng với văn bia đó.

- **Đối với các chữ tồn tại, nhưng không có font hoặc bị cắt dán thẳng vào PDF**: Biểu diễn bằng kí tự @ với mỗi chữ bị thiếu/ sai font (xem Hình 10). Trường hợp mà chữ trong JSON khác với chữ ở phần text trong PDF và không biết cần thay thế từ gì vào thì cũng dùng kí hiệu @.



Hình 10: Ví dụ chữ không hỗ trợ font nên dán ảnh vào PDF

- **Đối với các từ mà bộ font hiện tại trên web không biểu diễn được**: Biểu diễn bằng kí tự @ với mỗi chữ bị thiếu/ sai font.

  Gợi ý. Các kí tự loại này có thể nhận biết bằng cách, bên trong PDF thì có Character ở vị trí này (khác với Hình 8 và Hình 10), nhưng khi lên giao diện Website thì bị hiểu thị thành □ hoặc kí hiệu lạ khác.

- Thực hiện xóa tất cả các kí tự dấu mở ngoặc, đóng ngoặc (tròn , vuông, nhọn) được dùng để đánh dấu các trường hợp đặc biệt và trên văn bia không tồn tại các kí tự đó.

Ghi chú

Mỗi tài liệu sẽ có những cách biểu diễn khác nhau đối với chữ bị mất/ thiếu với số lượng khác nhau, ... vì vậy phải chú ý chuẩn hóa về theo quy định trên.

Bước 2: Thực hiện chỉnh sửa (gõ lại nếu cần thiết) nội dung bị mất/ thiếu/ sai đối với các phần nội dung full tiếng Việt (chữ Quốc Ngữ). Do đôi khi do thuật toán trích xuất text chưa bao phủ được tất cả các trường hợp nên có thể lấy nội dung dư hoặc thiếu.

Thực hiện kiểm tra nội dung cho tất cả các mục trong phần Content Verification, bao gồm: Tên bia, Địa điểm, Niên đại, Nguyên văn chữ Hán Nôm, Phiên âm Hán Việt, Toát yếu.

Bước 3: Thực hiện chuẩn hóa về mặt dấu câu, đảm bảo rằng nội dung trong PDF được trích xuất ra đúng.

Phím chức năng.

Ở phần kiểm tra nội dung có một số phím chức năng cần lưu ý:

1. `Save Content`: Thực hiện ghi nhận tất cả các nội dung đã kiểm tra và chỉnh sửa vào file kết quả *inscription_ content*.

   Ở phần này, nếu không nhấn `Save Content` mà trực tiếp nhấn `Next` để sang bước tiếp theo thì nội dung vẫn được lưu.

2. `Undo Changes`: Thực hiện trở về trạng thái lần gần nhất được Save.

Lưu ý.

- Thực hiện kiểm tra kĩ về mặt dấu câu (đặc biệt là dấu của phần chữ Hán Nôm), dấu xuống hàng, ...
- Thực hiện xóa hoặc thêm các dấu xuống hàng (enter) nếu cần sao cho khớp với PDF nhất. Để xác định xem vị trí nào xuống hàng trong dữ liệu, có thể kiểm tra mục `Content JSON`, vị trí xuống hàng sẽ được thể hiện bằng dấu `\n`.

- Tạm thời chưa quan tâm đến thông tin trên ảnh văn bia trong phần này.
- Mỗi văn bia sẽ có những **quy định khác nhau về cách kí hiệu** chữ không gán nhãn được, chữ được dự đoán, ... cần linh hoạt trong vấn đề này và xem xét kĩ phần quy định kí hiệu ở đầu PDF được cung cấp.

2.4.3 Kiểm tra, điều chỉnh Bounding Box và sắp xếp thứ tự

Mục đích. Đảm bảo tất cả các ký tự thuộc nội dung văn bia đều được xác định bằng Bounding Box. Đồng thời, các Bounding Box cần được sắp xếp theo đúng thứ tự đọc của văn bia để phục vụ cho việc gán nội dung ở các bước tiếp theo.

> Mỗi Bounding Box cần phải **bao phủ hoàn toàn một ký tự (character)**

Phạm vi gán nhãn. Chỉ giữ lại Bounding Box của các ký tự **thuộc nội dung văn bia cần gán nhãn**. Các ký tự nằm ngoài phạm vi này, chẳng hạn phần chữ xuất hiện ở vùng rìa của văn bia, cần được loại bỏ. Khi chưa xác định được vị trí bắt đầu hoặc kết thúc của phần nội dung cần gán nhãn, có thể đối chiếu với nội dung được trích xuất từ PDF để xác định.

Hướng dẫn. Ở bước này, người dùng có thể thực hiện các thao tác sau:

- **Điều chỉnh Bounding Box:** Kéo các góc của Bounding Box để thay đổi kích thước và phạm vi bao phủ ký tự. Ngoài ra, có thể thực hiện di chuyển toàn bộ box (số thứ tự đi theo box) để sắp xếp lại thứ tự đọc theo số thứ tự.
- **Chọn Bounding Box:** Nhấn vào một Bounding Box để chọn. Để chọn nhiều Bounding Box, giữ phím `Cmd/Ctrl` và nhấn lần lượt vào từng box, hoặc kéo chuột để quét chọn nhiều box cùng lúc.
- **Xóa Bounding Box:** Chọn một hoặc nhiều Bounding Box cần loại bỏ, sau đó nhấn `Delete Selected`.

  Ví dụ, trong Hình 1, phần chữ nằm ở vùng rìa màu trắng bên phải không thuộc phạm vi gán nhãn và không cần giữ lại Bounding Box ở các vị trí này.
- **Thêm Bounding Box:** Giữ phím `Option/Alt` và kéo chuột trên ảnh để tạo một Bounding Box mới.
- **Sắp xếp các Bounding Box theo thứ tự đọc**, có các cách sắp xếp như sau:
  - Nhập số từ bàn phím vào phần `Bounding Box Order`
  - Nhấn Sort Order:
    - *Đã có nhiều ô được selected*: Thuật toán sẽ sắp xếp các ô đó, cho phép nhập số thứ tự bắt đầu, nếu chưa đúng thì có thể di chuyển ô về đúng vị trí.
    - *Không có ô nào được chọn*: Sắp xếp tất cả.

  Nếu người dùng muốn xóa kết quả Order thì `Clear Order` cũng hoạt động theo cách tương tự.

  > Thứ tự đọc của nội dung trong hình ảnh văn bia là từ trên xuống dưới, **từ phải qua trái**, cần đánh số thứ tự đọc bounding box theo thứ tự này.

  Lưu ý. Trước khi thực hiện, số lượng Bounding Box và số lượng ký tự trong nội dung trích xuất không khớp nhau, *cần xác nhận nguyên nhân chênh lệch trước*. Nếu như đã xác nhận, nhưng lại thêm box/ xóa box thì cần xác nhận lại nếu có chênh lệch trước khi có thể sort lại.

- **Run Detection:** Chạy lại mô hình phát hiện để tạo lại các Bounding Box trên ảnh và ghi đè toàn bộ kết quả hiện tại.

Xử lí chữ không có nhãn (PDF). Trong PDF, đôi khi sẽ có một số văn bia do quá mờ nên ngay cả chuyên gia cũng chưa thể gán nhãn cho phần chữ đó (Hình 8). Vì vậy, cần phải quan sát ở phần content và tốt nhất là cố gắng tìm vị trí bounding box phù hợp cho những chữ này để vẽ bounding box.

Xử lý chênh lệch số lượng. Trong quá trình kiểm tra, số lượng Bounding Box trên ảnh có thể không khớp với số lượng ký tự trong nội dung được trích xuất từ PDF. Các trường hợp được phân loại như sau:

- `Missing Content`: Có ký tự xuất hiện trên văn bia nhưng không xuất hiện trong nội dung trích xuất từ PDF. Khi đó, số lượng Bounding Box có thể lớn hơn số lượng ký tự trong nội dung trích xuất.
- `Extra Content`: Có ký tự xuất hiện trong nội dung trích xuất từ PDF nhưng không xuất hiện trên văn bia. Khi đó, số lượng Bounding Box có thể nhỏ hơn số lượng ký tự trong nội dung trích xuất.

  Cần phải thật sự cẩn trọng khi báo cáo là ảnh bị lỗi này, đặc biệt là khi ảnh tồn tại một số vị trí mà chuyên gia cũng không gán nhãn được như Hình 8.

- `Other`: Các trường hợp chênh lệch khác không thuộc hai loại trên. Người dùng cần nhập mô tả lỗi trước khi xác nhận. Sau khi xác nhận và nhấn `Next`, chương trình sẽ chuyển trực tiếp đến bước xác minh cuối cùng. (không khuyến khích sử dụng lựa chọn này)

Khi ghi nhận chênh lệch, người dùng thực hiện các thao tác sau:

1. Chọn loại chênh lệch phù hợp và nhấn `Confirm Mismatch` để ghi nhận.
2. Nhấn `Clear` để xóa thông tin chênh lệch đã ghi nhận.
3. Đối với trường hợp `Other`, trường `Note` là bắt buộc để mô tả cụ thể vấn đề. Với `Missing Content` và `Extra Content`, trường này không bắt buộc.

   Ngay khi có sự thay đổi về số lượng thì việc xác nhận mismatch trước đó sẽ mất hiệu lực, người dùng cần xác nhận mismatch lại (nếu có) để có thể Sort.

2.4.4 Thực hiện gắn trạng thái bounding box và sắp xếp

Mục đích. Kiểm tra và thực hiện điều chỉnh các tác vụ liên quan đến nhãn Bounding Box, bao gồm:

- Sắp xếp text
- Đánh giá trạng thái chất lượng của từng bounding box
- Đánh giá nội dung đúng, sai hoặc thiếu.

Hệ thống lấy thứ tự sắp xếp bounding box trên văn bia và lần lượt gán các ký tự theo thứ tự của nội dung đã được trích xuất. Nếu thứ tự Bounding Box được xác định chưa chính xác, nội dung có thể được gán nhầm sang các Bounding Box khác.

Ghi chú

- Bước này giả sử là phần bouding box ở bước trước đã được đánh số theo đúng số thứ tự đọc thực tế và kích thước của các box đã được điều chỉnh hoàn thiện, nếu muốn sửa thì phải quay về bước trước.
- Ở phần này, `Source Text` là nguồn text trích ra từ PDF tương ứng với văn bia, có thể xem để so sánh và tham khảo, ngoài ra cũng cần lưu ý so sánh với bản thân hình ảnh văn bia.

Hướng dẫn.

- **Sắp xếp lại text**: Kéo thả các ký tự ở mục `Character Alignment` để sắp xếp lại sao cho mỗi ký tự được gán với đúng Bounding Box tương ứng trên ảnh. Thông thường chỉ dùng tính năng này ở hai trường hợp sau:
  - **Trường hợp** `Missing Content`: Số lượng box **Miss** được tạo cố định và người dùng đưa nó về vị trí của các kí tự có trên văn bia nhưng không có trong text.
  - **Trường hợp** `Extra Content`: Thực hiện kéo các kí tự không tồn tại về cuối mục Character Alignment sao cho chữ đó được đánh dấu `Excluded`, sẽ có cố định x chữ được đánh dấu excluded với x là (số lượng chữ - số lượng bounding box).



Hình 11: Ví dụ về Excluded

Lưu ý.

- **Character Alignment ở đây được sắp xếp theo thứ tự đọc thông tường, nghĩa là từ trái qua phải, từ trên xuống dưới** (số cột của phần này không tương ứng với cột trên ảnh)
- Khi thực hiện chỉnh sửa đối với một ảnh đã được gán nhãn, nếu ở bước trước mà bounding box bị chỉnh sửa về số lượng, thì character alignment sẽ bị reset lại theo Source Text.

- **Các trạng thái đặc biệt**:

– **Nghi ngờ nội dung (Suspicious):** Trong trường hợp **nội dung JSON được trích xuất từ PDF** đủ về mặt số lượng (và giống với text trong PDF) nhưng tồn tại ký tự **không khớp với ký tự thực tế trên ảnh**, nhấn vào bounding box của ký tự tương ứng và bật tùy chọn `Suspicious`.

> Đôi khi có cùng một character cùng nghĩa nhưng có thể biểu diễn bằng nhiều kiểu chữ khác nhau cũng đánh dấu là Suspicious nếu có sự khác biệt giữa văn bia và Source Text PDF.
> **Ví dụ:** Chữ Giản thể và Phồn thể.

– **Đánh dấu sai/ thiếu font:** Đối với trường hợp phần Text đã được biểu diễn bằng @, thực hiện bật `Unavailable Font` thành `True`.

– **Đánh dấu chữ là kết quả dự đoán của chuyên gia:** Thực hiện bật trạng thái `Expert Prediction` thành `True`.

– **Đánh dấu Unknown (mất chữ - □):** Đối với các trường hợp bounding box mà ngay cả nguồn PDF được cung cấp cũng không gán được nhãn kí tự cho vị trí đó (Hình 8), thực hiện chọn cho mục `Unknown` với giá trị `True`, còn lại mặc định là `False`. Cần lưu ý, đối với các chữ là Unknown thì phần đánh giá độ nguyên vẹn của chữ luôn luôn là **Damaged**.

Lưu ý. Ký tự này vẫn được giữ lại trong dữ liệu gán nhãn nhưng sẽ được đánh dấu để phục vụ việc kiểm tra lại sau (nếu cần).

Cần lưu ý, trường hợp Sai/ thiếu font có thể được bật cùng lúc với trạng thái Expert Prediction, nhưng khi bật Unknown thì hai trạng thái kia mặc định bị tắt.

- **Gán trạng thái:** Thực hiện chọn trạng thái khi chọn từng ký tự, nghĩa là chọn bounding box của kí tự mình muốn chỉnh trên image (không chọn trong character alignment). Các ký tự được phân loại theo các trạng thái sau:

  – **Viền màu xanh – vị trí nguyên (intact):** Ký tự còn nguyên vẹn, có độ sắc nét cao và không bị mất nét.

  – **Viền màu đỏ – vị trí hỏng (damaged):** Ký tự có dấu hiệu bị mờ, mất nét, nét bị dính liền vào nhau hoặc hư hỏng, khiến việc xác định chính xác từng nét của ký tự gặp khó khăn.

  Ở đây định nghĩa ba mức độ hư hại mà người gán nhãn cần chú ý:

  * **Mức 1 – Hư hại nhẹ (Light Damage)**: Ký tự vẫn giữ được phần lớn các đặc điểm cấu trúc, cho phép nhận diện một cách đáng tin cậy mặc dù có những dấu hiệu hư hại rõ ràng. Nói cách khác là mặc dù chữ bị mờ nhưng vẫn biết là có nét gì, đọc được gần như toàn bộ nét của chữ.
  * **Mức 2 – Hư hại trung bình (Medium Damage)**: Ký tự bị hư hại đáng kể về cấu trúc nhưng vẫn có thể nhận diện được thông qua việc quan sát và kiểm tra kỹ lưỡng. Nói cách khác là ở mức giữa của Light và Severe Damage, phần chữ không đọc được khoảng 40-70%.
  * **Mức 3 – Hư hại nghiêm trọng (Severe Damage)**: Ký tự bị mất hoàn toàn tính toàn vẹn về cấu trúc, khiến việc nhận diện trở nên bất khả thi ngay cả khi được các chuyên gia kiểm tra. Nói cách khác là gần như toàn bộ chữ đều bị hư, khoảng tầm 90% nội dung bị hỏng hoàn toàn, không thể nhận biết ra là chữ gì.

  Có thể quan sát ví dụ dưới đây để tham khảo:



Hình 12: Một số ví dụ về 3 mức độ hư hại

– **Viền màu vàng**: được dùng để đánh dấu đặc biệt cho chữ được chuyên gia dự đoán dựa trên nội dung (do quá mờ hoặc mất chữ nên không thể đọc trực tiếp được từ văn bia).

Lưu ý. Ở phần đánh dấu là chữ Nguyên hoặc Hồng, chỉ xét đến độ mờ hoặc rõ của kí tự trên văn bia, không cần xem xét đến việc nội dung đó là đúng, sai hay thiếu.

- **Load lại ảnh:** Nhấn nút `Apply Changes` để xem lại ảnh với trạng thái và thứ tự sắp xếp mới được vẽ lại.

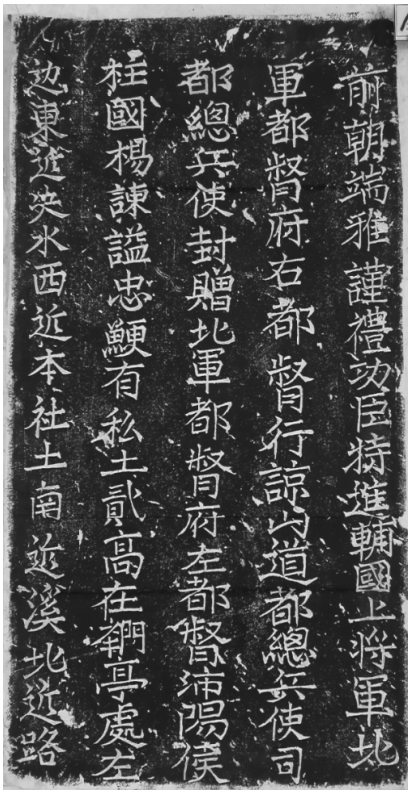
Ghi chú

Việc đánh dấu là đánh dấu được lưu Bounding Box chứ không phải là lưu trên chữ, vì vậy, khi thay đổi vị trí của các chữ, thì trạng thái của Bounding Box vẫn giữ nguyên, nhưng chỉ đổi nhãn chữ được gắn với Box đó.

2.4.5 Cắt vùng ảnh không chứa thông tin (Crop)

Mục đích. Loại bỏ các vùng rìa của ảnh không chứa thông tin liên quan đến văn bia, từ đó tạo ra ảnh đầu vào cuối cùng tập trung vào khu vực cần gán nhãn. Việc cắt bỏ các vùng không cần thiết cũng giúp giảm kích thước dữ liệu và hạn chế tài nguyên cần sử dụng trong quá trình xử lý ảnh.

Cụ thể, phần được giữ lại là phần văn bia, thường có màu đen, chú ý loại bỏ các vùng chứa nội dung ghi chú ở ngoài. Có thể nhận biết những vùng chữ không cần thiết bằng cách là những phần hình ảnh đó có chữ nhưng PDF không có nhãn.



Hình 13: Crop minh họa đối với Hình 1

Hướng dẫn. Người dùng điều chỉnh vùng cắt trực tiếp trên ảnh hoặc nhập tọa độ để xác định chính xác vùng ảnh cần giữ lại.

- Khi điều chỉnh bằng tọa độ, nhấn `Apply Crop` để áp dụng và lưu vùng cắt.
- Khi điều chỉnh trực tiếp trên ảnh, thay đổi sẽ được tự động lưu khi nhấn `Next`.

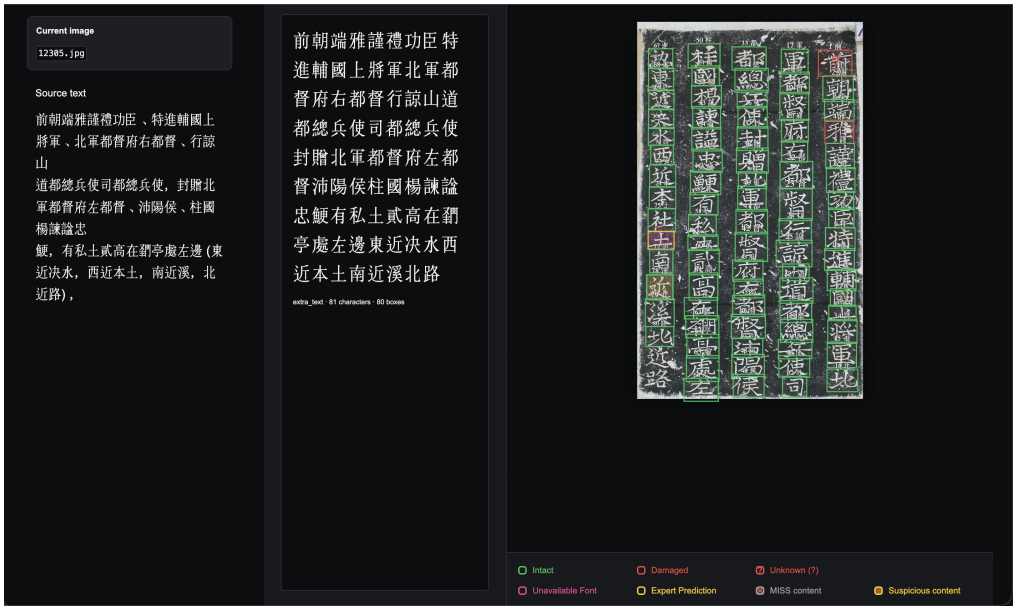
Lưu ý. Nếu ảnh có độ phân giải quá cao, với ít nhất một cạnh lớn hơn `4096 px`, chương trình sẽ tự động thu nhỏ ảnh theo đúng tỉ lệ sao cho cạnh lớn nhất không vượt quá `4096 px`.

2.4.6 Xác minh lại thông tin

Người dùng kiểm tra lại toàn bộ kết quả gán nhãn trên giao diện xác minh cuối cùng. Tại đây, kết quả gán nhãn được hiển thị cùng với nội dung văn bản gốc đã trích xuất để thuận tiện cho việc đối chiếu và xác nhận tính chính xác.

> Sau khi hoàn tất kiểm tra, nhấn `Save Annotation` để lưu kết quả của ảnh hiện tại vào tệp tin tổng hợp kết quả gán nhãn.

Để kiểm tra xem liệu dữ liệu có lưu đúng và load lên đúng chưa, có thể thực hiện chọn lại ảnh vừa gán nhãn và kiểm tra xem ở từng bước xem thông tin được lưu có giống với những gì mình vừa gán nhãn không.



Hình 14: Giao diện xác minh

2.5 Yêu cầu nộp bài

Nội dung nộp bài:

- Các file `.json` chứa nội dung gán nhãn (3 file ở dưới).
- Một file PDF `summary.pdf` chứa bản tóm tắt quy trình gán nhãn.

Các file này được nén lại thành một file `<MSSV>.zip` để nộp.

Trong suốt quá trình thực hiện, người dùng cần có thể tải về các file `.json` sau thông qua giao diện:

- `inscription_content.json`: Lưu trữ nội dung văn bản của từng văn bia được trích xuất từ tệp PDF nguồn, phục vụ cho quá trình đối chiếu và gán nhãn dữ liệu.
- `text_annotations.json`: Lưu trữ thông tin chú thích tương ứng với từng ảnh văn bia, bao gồm tọa độ vùng cắt ảnh, tọa độ các bounding box, nhãn văn bản tương ứng, trạng thái của từng vùng (*intact* hoặc *damaged*) và thứ tự đọc (*reading order*).

  Lưu ý. Các văn bia mà bản thân text từ PDF có chứa các nhãn mà người gán nhãn không nhận diện được (Hình 8) cũng được lưu ở phần này.

- `source_mismatches.json`: Lưu trữ thông tin chú thích tương ứng với từng ảnh của văn bia, nhưng trong trường hợp nguồn nhãn trong văn bản không khớp với văn bia. Cụ thể là các ảnh bị *Missing Content*, trường hợp *Extra Content* hoặc `Other`.

Những file này có thể trực tiếp được tải về dưới dạng file `.zip` thông qua nút `Download all` trên giao diện (góc trên bên phải), cần phải kiểm tra luôn luôn có đủ các tệp tin này thì mới đạt yêu cầu (file nào không có record sẽ là mảng rỗng).

Ghi chú

- Dữ liệu chưa được lưu có thể bị mất khi kết thúc phiên Kaggle. Vì vậy, nên tải kết quả định kỳ bằng nút **Download All**.
- Nếu tải nhiều lần, chẳng hạn thành hai file `annotation-1.zip` và `annotation-2.zip`, cần giải nén và gộp riêng từng file JSON cùng tên bên trong hai file ZIP. Cách gộp là đưa các object vào chung một array, không nối trực tiếp nội dung văn bản của hai file JSON (có thể tham khảo ví dụ file trên SinoNom-Annotation).
- Nếu cùng một ảnh xuất hiện trong nhiều lần lưu, chỉ giữ bản ghi ở lần lưu mới nhất để tránh trùng lặp.